# 基于 ClamAV 和 RF 的安卓恶意代码检测器 课程作业汇报

第九组: 冯驰, 姚思悦, 何梓欣, 韩雨虹

指导老师:刘功申

2022 年 4 月 7 日



- ① 运行环境
- ② 病毒检测
- 3 ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示

- ① 运行环境
- ② 病毒检测
- ③ ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示



## 系统运行环境

• 操作系统: openEuler20.03-LTS-SP3

• 桌面环境: UKUI

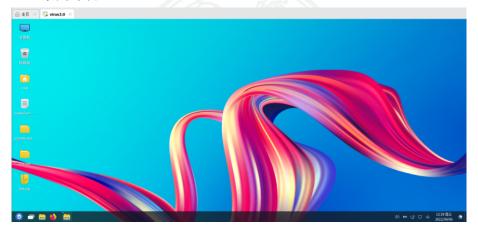


Figure: 操作系统桌面

- ① 运行环境
- ② 病毒检测
- ③ ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示



# 检测方法概述

- 检测原理:
  - 将安卓软件反编译, 提取字节编码
  - 将字节码分为 MRGITPV 七类, 并进行分类映射
  - 使用滑动平均窗口提取 3-gram 特征
  - 使用随机森林训练分类器
- 检测框架:



Figure: 检测框架



### 数据集

- 恶意软件:来自 virusShare,729 个,共约 1.57G https://virusshare.com
- 良性软件:来自 UNB2015 和 2017 (加拿大网络安全研究所),686 个,共约 6.75G https://www.unb.ca/cic/datasets



## 模块实现——反汇编

batch\_disasseble.py: 将安卓 apk 从指定目录反汇编出对应的字节 编码

```
disassemble(frompath, topath, num, start=0):
   files = os.listdir(frompath)
   files = files[start:num]
   total = len(files)
   for i, file in enumerate(files):
       fullFrompath - os.path.join(frompath, file)
       fullTopath - os.path.join(topath, file)
       command = "apktool d " + fullFrompath + " -o " + fullTopath
       subprocess.call(command, shell=True)
       print("已反汇编", i+1, "个应用")
       print("百分比为: ",(i + 1) * 100 / total, "%")

← > ← © Home APK-ngram-RF-master smalls → 
O Recent
                   kind
                         malwar
                                  test
```

Figure: 存放反汇编文件至指定目录



# 模块实现——字节编码映射

bytecode\_extract.py: 将字节编码取出并映射,保存映射后的文件

```
def collect(rootdir, isMalware):
    wares = os.listdir(rootdir)
    total = len(wares)
    for i, ware in enumerate(wares):
       warePath = os.path.join(rootdir, ware)
       ware = Ware(warePath, isMalware)
       ware.extractFeature(f)
       print("已提取", i + 1, "个文件的特征")
       print("百分比为: ",(i + 1) * 100 / total, "%")
```

Figure: 映射函数

## 模块实现——3-gram 特征提取

• n\_gram.py: 将映射后的编码滑动平均提取 3\_gram 特征

```
def gram():
   n = int(sys.argv[2])
   origin = pd.read csv("data.csv")
   mdict = MvDict()
   feature = origin["Feature"].str.split("|")
   total = len(feature)
   for i, code in enumerate(feature):
       mdict.newLayer()
       if not type(code) == list:
       for method in code:
           length = len(method)
           if length < n:
           for start in range(length - (n - 1)):
               end = start + n
               mdict.mark(method[start:end])
   print("已完成", i+1, "个应用")
   print("百分比为: ",(i + 1) * 100 / total, "%")
   result = mdict.dict
   result['isMalware']=origin.isMalware
   pd.DataFrame(result, index=origin.index)\
               .to_csv("./" + str(n) + "_gram.csv", index=False)
```

Figure: 提取 3-gram 特征

## 模块实现——随机森林分类器

• 1461 个样本 (白样本 686, 黑样本 729), 验证集准确率为 94.17%。

```
x_train: 892
x test white: 25
```

# 模块实现——随机森林检测器

- 保存训练好的模型
- 构建 python 脚本对每个 apk 文件处理后得到 3-gram 特征
- 加载分类器模型进行检测,可辨别是否为恶意代码软件



- 1 运行环境
- ② 病毒检测
- ③ ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示

## 源码安装 ClamAV

- 编译安装 ClamAV
- 遇到的问题:
  - 选择 0.103.1 版本后,系统提示版本较低,最终选择 0.103.5 版本
  - 缺少较多依赖库, 需要手动安装
  - 无法识别 freshclam 及 clamscan 指令,需要软连接或者通过路径调用

```
Known viruses: 8609038
Engine version: 0.103.5
Scanned directories: 1
Scanned files: 45
Infected files: 0
Data scanned: 4.49 MB
Data read: 2.23 MB (ratio 2.01:1)
Time: 55.738 sec (0 m 55 s)
Start Date: 2022:04:06 13:15:27
End Date: 2022:04:06 13:16:23
[root@localhost clamav]#
```

Figure: 安装完 clamscan 扫描结果

## 定位 apk 检测

#### ● ClamAV 原生没有 apk 检测的 type



# 定位 apk 检测

 对 apk 的检测会将其碎片化,然后调用 CL TYPE MACHO UNIBIN:和CL TYPE BINARY DATA 类型 的检测。

```
switch (type) &
       perf_nested_start(ctx, PERFT_SCRIPT, PERFT_SCAN);
        if ((DCONF_DOC & DOC_CONF_SCRIPT) && dettype != CL_TYPE_HTML && (ret != CL_VIRUS || SCAN_ALLMATCHES) && SCAN_PARSE_HTML)
           ret = cli scanscript(ctx);
        if (SCAN_PARSE_MAIL && (DCONF_MAIL & MAIL_CONF_MBOX) && ret != CL_VIRUS && (cli_recursion_stack_get_type(ctx, -1) == CL_TY
            ret = cli_scan_fmap(ctx, CL_TYPE_MAIL, 0, NULL, AC_SCAN_VIR, NULL, NULL);
        perf_nested_stop(ctx, PERFT_SCRIPT, PERFT_SCAN);
   case CL TYPE MSEXE:
       perf nested start(ctx, PERFT PE, PERFT SCAN):
           unsigned int corrupted input = ctx->corrupted input;
        perf nested stop(ctx, PERFT PE, PERFT SCAN):
       perf nested start(ctx, PERFT ELF, PERFT SCAN);
       ret = cli_unpackelf(ctx);
        perf nested stop(ctx, PERFT_ELF, PERFT_SCAN);
       perf nested start(ctx, PERFT MACHO, PERFT SCAN);
       ret = cli_unpackmacho(ctx);
       perf_nested_stop(ctx, PERFT_MACHO, PERFT_SCAN);
        ret = cli_scan_fmap(ctx, CL_TYPE_OTHER, 0, NULL, AC_SCAN_VIR, NULL, NULL);
```

# 定位 apk 检测

向前定位,找到除了以上这些类型之外的文件分类位置。在此添加 函数判断其是否为 apk 文件。

```
if (FSTAT(desc, \&sb) == -1) {
    cli errmsq("cl scandesc callback: Can't fstat descriptor %d\n", desc);
    goto done:
if (sb.st size <= 5) {
    cli_dbgmsg("cl_scandesc_callback: File too small (" STDu64 " bytes), ignoring\n", (uint64_t)sb.st_size);
    goto done:
if ((engine->maxfilesize > 0) && ((uint64_t)sb.st_size > engine->maxfilesize)) {
    cli_dbgmsg("cl_scandesc_callback: File too large (" STDu64 " bytes), ignoring\n", (uint64_t)sb.st_size);
    if (scanoptions->heuristic & CL SCAN HEURISTIC EXCEEDS MAX) {
        if (engine->cb_virus_found)
            engine->cb virus found(desc, "Heuristics.Limits.Exceeded.MaxFileSize", context);
        status = CL VIRUS:
    } else {
        status = CL CLEAN:
    goto done:
if (NULL != filename) {
    (void)cli basename(filename, strlen(filename), &filename base);
if (NULL == (map = fmap(desc, 0, sb.st size, filename base))) {
    cli errmsq("CRITICAL: fmap() failed\n");
    status = CL EMEM:
    goto done;
```

4 D > 4 AB > 4 B > 4 B >

## 用 c 调用 python 检测

已经封装了随机森林检测病毒脚本。于是在 scanners.c 中用 c 调用, 并读取脚本的返回值,用于下一步的判断。

```
int exec process(char *cmd, char *result, int size)
   if(cmd == NULL)
   fp = popen(cmd."r"):
       printf("exec process: error exec cmd: %s\n", cmd);
   if(result != NULL && size > 0)
        memset(result, 0, size);
       ret = fread(result, 1, size - 1, fp);
        if(ferror(fp))
           pclose(fp):
           return -1;
        if(ret == 0) {
           nclose(fn):
   pclose(fp);
int detect(const char *file_name, const char *file_namebase){
   char hhhhh[1000] = "python3 /home/group9/test.py ":
   strcat(hhhhh, file_name);
   strcat(hhhhh. " "):
   strcat(hhhhh, file_namebase);
   char popenret[100000] = {0}:/*执行脚本后的返回值*/
   memset(popenret, 0, sizeof(popenret));
```

# 调用函数改写

● 检测结果是以 status 存储的,类型为 CL\_VIRUS,CL\_CLEAN,并会在 ClamAV 终端输出返回值。

```
int temp = 0;
int temp = 0;
if (is_apk(filename)){
    temp = detect(filename,filename_base);
    if (temp == 1){
        status = CL_VIRUS;
        engine->cb_virus_found(desc, "Group9 detected virus", context);
    }
else if (temp == 2){
        status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
    }
else status = CL_CLEAN;
}
else
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, engine, scanoptions, context);
status = scan_common(map, filename, virname, scanned, en
```

# 修改后的 apk 文件检测结果

• 重新编译后运行 clamscan 已经可以达到我们想要的检测结果。

Figure: 可以检测出病毒文件

- 1 运行环境
- ② 病毒检测
- 3 ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示

## ClamTK 安装与修改

- 通过源码安装 ClamTK
- 对 GUI.pm 进行修改
  - 将界面标题修改为 "ClamTK Virus Scanner of Group9"
  - 增加名为 "Group9" 的按钮, 描述为 "Group9 clamscan"

```
$hb->set_title( _( 'ClamTk Virus Scanner of Group9' )
$hb->set_decoration_layout('menu,icon:minimize,close');
$hb->set show close button( TRUE );
 my $dialog = Gtk3::AboutDialog->new;
 my $license

    'ClamTk is free software; you can redistribute it and/or'

 $dialog->set wrap license( TRUE );
 $dialog->set position( 'mouse' );
 my $images_dir = ClamTk::App->get_path( 'images' );
             - "Simages dir/Des
              = Gtk3::Gdk::Pixbuf->new_from_file( $icon );
                => _('Group9'),
             description => _('Group9 clamscan'),
                            => 'media-playback-start'.
            button
                            => FALSE,
```

## 前端修改后界面展示



Figure: 修改后的界面

## ClamTK 成功运行

• ClamTK 成功调用 ClamAV 扫描 apk 文件

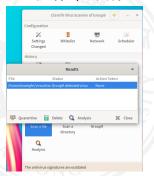


Figure: 扫描一个病毒文件并识别

- 1 运行环境
- ② 病毒检测
- ③ ClamAV 的修改及应用
- 4 ClamTK 的修改及应用
- 5 总结与演示



## 项目成果与不足

#### 一、 成果:

1、 本组在 openEuler 操作系统上,修改 ClamAV 源码,并使用随机森林 模型检测 apk 格式的恶意代码文件,检测结果良好。

#### 二、 不足之处与解决方法

- 1、 假阳性概率较高: 目前只是用了随机森林来训练, 改进可以使用层次 结构更复杂的其他神经网络
- 2、 反编译时间较长, clamscan 调用过程时占用内存空间较大: 目前使用了基于 java 的 apktool,内存占用高。改进可以使用 c 语言原生的 java 反编译库

Thanks! 谢谢! ありがとう! ¡Gracias! Grazie! Merci! Mulţmesc!



**分享人**: 冯驰 F19 信息安全

